Do kedy?

Keďže všetci robíte radi s predstihom, deadline je 31.12.2021 o 23:59.

Co odovzdať?

Dotazy v separátnom textovom editore + dotaz a screenshot výsledku v pdf.

Hodnotenie

Úlohy spolu za 10 bodov rozdelené nasledovne:

- 1,2,3,4,5 a 6 sú za jeden bod,
- 7, 8 za 2 body.
- Bonus za 2 extra body.

Zadanie - Neo4j

V odpovediach nepoužívajte na zoraďovanie existujúce polia followers_count, retweet_count, etc. Tieto hodnoty sú prevzaté z Twitteru a nezodpovedajú našim vzťahom v datasete. Pri počítaní početnosti followerov, retweetov a podobne vždy počítajte zodpovedajúce vzťahy medzi uzlami.

- 1. Zoberte si nami vytvorený dataset z vašich tweetov:

 https://drive.google.com/file/d/1kufTAFP5DH8hiCT-BRLHqAicoulJ_0Qi/view?usp=sharing
 a importujte ho cez neo4j-admin
- Vypíšte 5 Accountov s najvyšším množstvom followerov. Nezoraďujte Accounty podľa poľa followers_count. Zaujímajú nás followujúce Accounty v našom datasete cez vzťah FOLLOWS.
- 3. Nájdite najkratšie cesty medzi Katy Perry {screen_name: 'katyperry'} a Kim Kardashian {screen_name: 'KimKardashian'} cez vzťah FOLLOWS. Všetky cesty, kde Kim Kardashian followuje niekoho, kto followuje niekoho, kto..., kto followuje Katy Perry.
- 4. Vyhľadajte neúspešné tweety influencerov. Vyhľadajte 10 najmenej retweetovanych tweetov od Accountov, ktoré sú na prvých 10 miestach v celkovom počte retweetov.
- 5. Vytvorte volaním iba jednej query nový Account s Vašim menom, ktorý bude followovať Donalda Trumpa {screen_name:"realDonaldTrump"} a v tom istom volaní vytvorte tweet, ktorý bude retweetom Donaldovho najretweetovanejšieho tweetu.
- 6. Odporučte používateľovi {screen_name:"777stl"} followovanie ďalších Accountov, na základe followovania rovnakých Accountov: Vyhľadajte 10 Accountov, ktoré followujú najviac rovnakých Accountov ako náš používateľ, ale náš používateľ ich ešte nefollowuje.
- 7. Odporučte používateľovi {screen_name:"DaynerWilson"} followovanie ďalších Accountov na základe zhody v retweetovaní rovnakých tweetov: Vyhľadajte 10 accountov, ktoré retweetli najviac tých istých tweetov, ako náš používateľ. Ak tweet ktorý retweetujeme, je už tiež

- retweetom, rátajte za zhodu aj retweetovanie jeho parent tweetu retweetovanie teda zohľadňujte rekurzívne.
- 8. Vyhľadajte 5 tweetov ostatných Accountov, ktoré do hĺbky 5 followujú account, ktorý napísal tweet {id: "1289380305728503808"}, ktoré síce nie sú retweetom vybraného tweetu, ale napriek tomu majú čo najviac rovnakých slov v poli content zhodných s vybraným tweetom (stačí rozdeliť content na slová cez split(tweet.content, " "). Account, ktorý followuje Account, ktorý follow uje nami vybraný Account rozumieme hĺbkou 2. Odporúčam pozrieť si procedúry v knižnici APOC pracujúce s collections, ale nie je to podmienkou na zvládnutie úlohy.

BONUS: Nájdite najkratšie cesty medzi Katy Perry (katyperry) a Donaldom Trumpom cez vzťah RETWEETS (a tým pádom aj POST). Všetky cesty, kde Katy Perry retweetla post Accountu, ktorý retweetol post Accountu, ktorý..., ktorý retweetol post Donalda Trumpa.


(Account) -> [POSTS] -> (Tweet) - [RETWEETS] -> (Tweet) <- [POSTS] - (Account) - [POSTS] -> (Tweet) - [RETWEETS] -> (Tweet) <- [POSTS] - (Account) -> ...

Github: https://github.com/jaruji/neo4j-PDT

1. Neo4j sa mi podarilo rozchodiť v dockeri, dump som musel definovať cez docker-compose.



2. Query je zapísané aj v separátnom textovom súbore, výsledok vyšiel nasledovný:



Vypísal som si pre zaujímavosť aj pôvodný follower_count (zoraďoval som však podľa countu follow vzťahov z neo4j db).

3. Zistil som prostredníctvom query, že aká je najkratšia cesta medzi katyperry a KimKardashian -



Dĺžka cesty je 1, keďže existuje aspoň jeden účet ktorý followuje aj katyperry aj kimK. Keďže v zadaní máme nájsť všetky cesty, použijeme funkciu allShortestPaths namiesto shortestPath. Toto query vráti dosť výsledkov, graf mi niekam úplne zmizol.



Started streaming 304 records after 1 ms and completed after 452 ms.

Pridávam ukážku zopár prvých výsledkov:



4. Úlohu som spravil cez subquery prostredníctvom CALL funkcie. Najprv si vyberieme 10 najviac retweetovaných účtov, následne nad touto množinou hladáme 10 najmenej retweetovaných tweetov. Selectoval som zaujímavé hodnoty ako názov účtu, tweet_id, tweet content, počet retweetov účtu a počet retweetov samotného tweetu.



Výsledky:

"name"	"acc_retweet_count"	"tweet_id"	"content"	"tweet_retweet_count'
"ewarren"	1883		"Last night, the federal evictions moratorium expired, and rent is due next week-the same week coronavirus unemployment benefits are set to en	1
his is a complete	ly preventable crisi		mmediately to extend these critical protections.	
ttps://t.co/9gALM	lcbR3k"	1		
"CarlosLoret"	1486	"1289243214428303360"	"Este estudio en el Bwashingtonpost dice que para reabrir las universidades habria que hacer una prueba de Covid cada dos dias a los alumnos h ttps://t.co/e5f4wIguxG"	2
"replouiegohmert"	1613	"1288554276231548929"	"Lots of #FakeNews going around about this https://t.co/OQhHYZJZvh"	3
"ewarren"	1883	"1289255470293757955"	"We know what we need to do to contain the virus and save lives and our economy—but Republicans refuse to invest enough in widespread testing and contact tracing \n	3
rump and his Repu		have what it takes to	Qet us out of this orisis.	
"CarlosLoret"	1486	"1288962040401399815"	"Para morirse de envidia: cómo Francia está viviendo su nueva normalidad. Este articulista sale a restaurantes, va a conciertos y a centros co merciales. El truco: pruebas y rastreo de contactos. https://t.co/XcVGGTTZOF"	6
"ewarren"	1883	"1289287273880547328"	"We need to make sure schools have all the resources they need to determine whether and how to safely reopen. Anything less is recklessly end ngering lives for political gain, \nhttps://t.co/XXWQTYRF4"	10
"CarlosLoret"	1486	"1289354415372025858"	"688 fallecimientos documentados en 24 horas, ya son 46 mil 688 decesos por #Covid en #México. https://t.co/gh6x8hYCt2"	12
"CarlosLoret"	1486	"1289417499654541312"	"Murió Paco Valverde, un gran luchador por la naturaleza, valiente defensor de la Vaquita Marina. Hubo una enorme solidaridad para tratar de alvazio. Cracias a codos los que estuvieron pendientes. Desoanse en Par el buen pescador. Abraso entrañable para Alan y toda su familia. http: //k.co/darut/lepto*	
"maddieevelasco"	3143	"1288978547898322945"	"2. You put employees at risk for getting sick. Yes we wear a mask, but we are there to serve you and have families and friends we are afraid to be around now because we don't know how long ago we came in contact with someone or if we are infected until it's too late."	54
	3143		"1. You put yourself at unnecessary risk of contracting covid-19. We sanitize as often as we can, but you still take your mask off to eat arc	. 66

5. V tejto úlohe bolo potrebné najprv nájsť najviac retweetovaný tweet účtu Donalda Trumpa prostredníctvom subquery (CALL rovnako ako predošlá úloha). Následne pomocou CREATE môžeme vytvoriť nový účet, ktorému cez vzťah FOLLOWS pridáme follow na Trumpov účet a cez vzťah POSTS vytvoríme nový tweet s ľubovoľným obsahom.



6. Cez CALL som si vybral účet používateľa 777stl a účty ktoré followuje. Následne som hľadal iné účty ktoré followujú tieto účty a počítal prekryv, resp. početnosť zhodných účtov ktoré followujú s prvotne vybraným účtom. Bolo potrebné ošetriť aj situáciu, aby sme nenašli rovnaký účet (cez acc1 <> acc2).



7. Pomocou CALL som si vybral všetky tweety ktoré retweetuje používateľ DaynerWilson, následne som hľadal zhodu prostredníctvom tejto predom vybranej množiny tweetov. Výsledkov mi našlo iba 7.




8. V prvom rade bolo potrebné spojazdniť APOC, keďže treba mat v plugins .jar file inak tie funkcie nezbehnú. Nainštaloval som to cez docker CLI príkazom wget na najnovšiu APOC verziu a následne reštartom neo4j. Pri úlohe som postupoval nasledovne: najprv som si vybral tweet, všetky účty ktoré followujú účet ktorý tweetol tweet do hĺbky 5 (neviem či mám dávať 0-4 alebo 1-5 hĺbku podľa toho čo je napísane v zadaní - dával som 1-5 ale skúšal som aj 0-4 a výsledky boli trochu odlišné, 1-5 našlo o jednu 6 slovnú zhodu viac) a všetky tweety týchto účtov, ktoré nie sú retweetom nášho pôvodného tweetu. Nasledovne som cez APOC funkciu intesection vyhľadával počet zhodných slov medzi dvoma listami (získanými cez split s parametrom "") a podľa počtu zhôd som následne našiel najpodobnejšie tweety. Najlepší match bol 6 slov.



BONUS:

Podarilo sa mi nájsť najkratšiu cestu, no nevedel som ako použiť shortestPath ak chceme mať komplexnú sekvenciu relationships, preto som vyhľadával medzi množinou tweetov katyP a donaldaT najkraťsiu cestu cez retweets vzťah. Dĺžka cesty bola 1 (katyP retweetla účet ktorý retweetol donalda s obsahom tweetu "Cool Retweet donaldovho Tweetu). Najkratšia cesta bola iba jedna.



```
"p"

[{"happened_at_str":"2020-03-28 02:29:57+00","favorite_count":122342,"
id":"1243726993537073152","author_id":"25073877","content":"I love Mic
higan, one of the reasons we are doing such a GREAT job for them durin
g this horrible Pandemic. Yet your Governor, Gretchen "Half" Whitmer i
s way in over her head, she doesn't have a clue. Likes blaming everyon
e for her own ineptitude! #MAGA","retweet_count":23858},{},{"content":
"Cool Retweet donaldovho tweetu"}]
```